штурвал

лаборатория ЧИСЛИТЕЛЬ

ENTERPRISE-РЕДАКЦИЯ

ШТУРВАЛ ML/AI



Готовая платформа для ML- и AI-нагрузок
в Kubernetes на CPU и GPU

до 80% экономии на GPU
и эксплуатации

штурвал

1 ВЕСЬ ML-СТЕК ИЗ КОРОБКИ

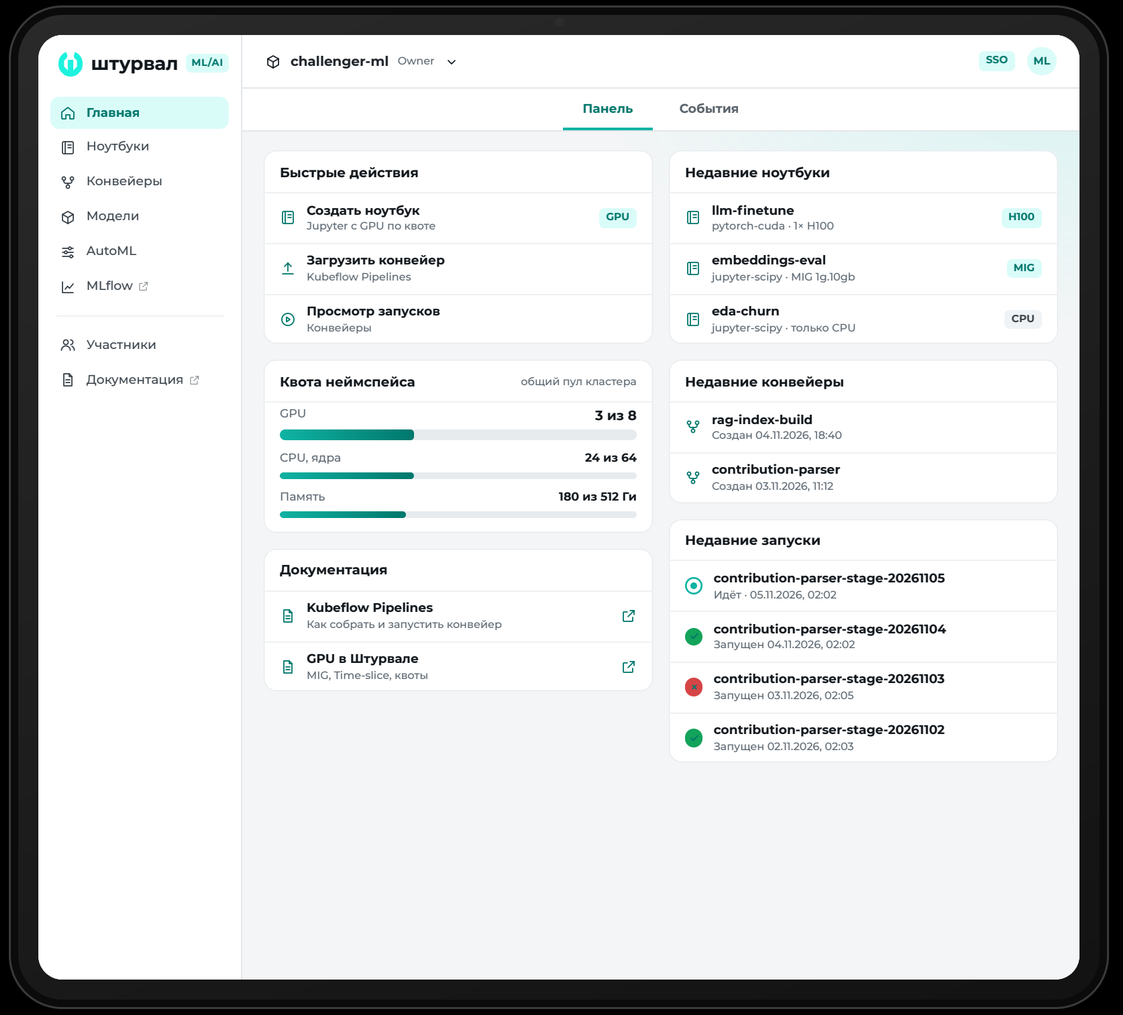
Администратор включает ML в кластере. Драйверы, Kubeflow и MLflow ставит платформа.

2 ОБЩИЙ ПУЛ GPU

Карту получает задача из очереди, а не человек, за которым она закреплена.

3 ОБНОВЛЕНИЕ ПО КНОПКЕ

GPU- и ML-стек обновляется вместе с кластером. Совместимость проверяет команда Штурвала.



штурвал

Вы экономите на четырёх статьях

НА СБОРКЕ

Стек ставит платформа

GPU Operator, Kubeflow, MLflow, SSO и квоты включаются в клиентском кластере. Не нужны месяцы работы платформенной команды и своя матрица совместимости.

НА ПОДДЕРЖКЕ

Сервисы уже есть

Мониторинг, ИБ, GitOps и бэкап для ML не ставят отдельно. Уязвимости ежедневно разбирает команда Штурвала и выпускает security-патчи.

НА ОБНОВЛЕНИЯХ

По кнопке, без проекта

Драйверы NVIDIA проверяются вместе с ядром, containerd, Kubernetes и Kubeflow. Стоимость проверки разделена между всеми заказчиками.

НА GPU

до 80%

Общий пул, квоты, MIG и автомасштабирование вместо отдельного сервера на команду. Закупки по фактической загрузке.

штурвал

01

ML-СТЕК В ПЛАТФОРМЕ

штурвал

Между вашим железом и вашими AI-сервисами

ПРИЛОЖЕНИЯ

GigaChat · T-Pro · Qwen · DeepSeek · Llama · GigaChat Enterprise · Just AI Agent Platform · LangGraph · n8n · SimpleOne GenAI · Sherpa AI · Directum · Docsvision

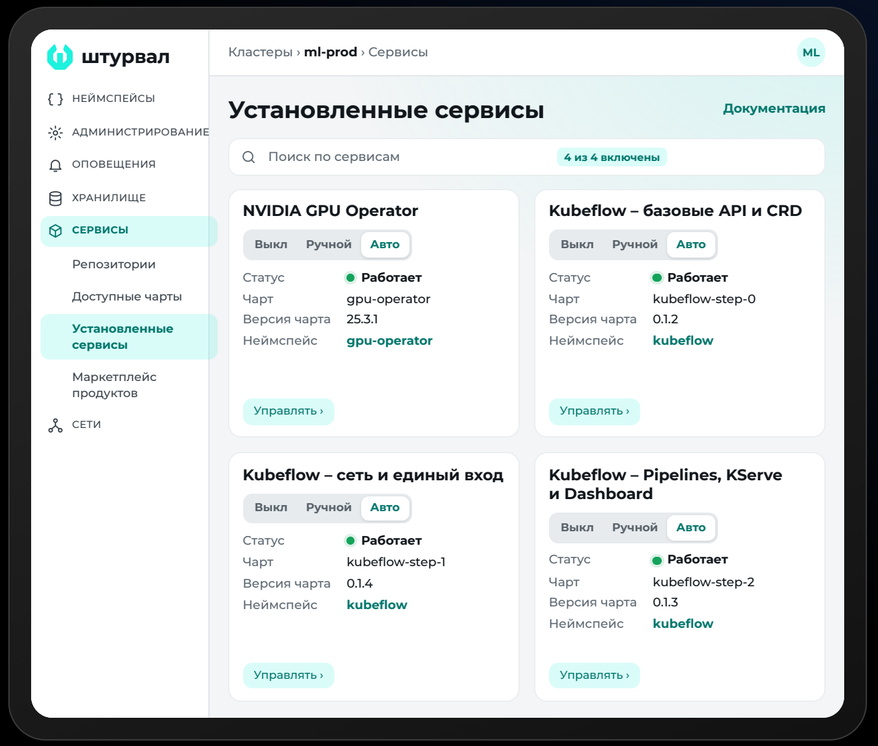
ШТУРВАЛ ML/AI

Выдаёт GPU по квотам, ставит и обновляет ML-стек. Не привязывает к экосистеме.

Kubernetes · GPU Operator · Kubeflow · MLflow · KServe и vLLM · квоты и RBAC

ЖЕЛЕЗО И GPU

NVIDIA A100 / H100 / L40S · bare metal · zVirt · vSphere · OpenStack · Yandex Cloud · S3



1. **Эксперимент** — Kubeflow Notebooks
2. **Обучение** — Pipelines · Training Op.
3. **Подбор параметров** — Katib
4. **Версия модели** — MLflow
5. **Инференс** — KServe · vLLM · Argo CD

штурвал

Каждый слой ставит и обновляет платформа

Доступ команд
кто и сколько ресурсов получает

- **Профили Kubeflow** — Неймспейс команды с квотами CPU и GPU
- **RBAC Штурвала** — Права на Kubeflow вместе с доступом к кластеру
- **SSO** — Вход корпоративной учёткой
- **LDAP / OIDC** — Тот же каталог, что у платформы

команда работает в своём профиле

Kubeflow
эксперименты, обучение, инференс

- **Notebooks** — Jupyter с запросом CPU или GPU
- **Pipelines** — Данные → обучение → проверка
- **Training Operator** — PyTorch, TF, MPI на узлах
- **Katib** — Подбор параметров
- **KServe** — Инференс, vLLM для LLM

метрики и артефакты →

MLflow
учёт моделей

- **Tracking** — Метрики и артефакты прогонов
- **Model Registry** — Версии и статусы

nvidia.com/gpu · MIG / Time-slice

Подготовка GPU
карта становится ресурсом планировщика

NVIDIA GPU Operator
Ставит и согласует компоненты справа как единый сервис кластера. Обновляется вместе со Штурвалом

Запуск	Обнаружение	Выдача и деление	Наблюдение
Драйвер NVIDIA	Node Feature Discovery	Device Plugin	DCGM Exporter
Container Toolkit	GPU Feature Discovery	MIG Manager	

ставится на GPU-группу узлов

CPU-узлы
Ноутбуки без GPU, подготовка данных, Kubeflow и MLflow
виртуализация: zVirt, vSphere, OpenStack

GPU-узлы
Обучение и инференс, автомасштабирование по запросу GPU
bare metal

Эксплуатация
для всех слоёв

- **Мониторинг, логи, алерты**
- **Trivy, Kyverno, аудит**
- **Argo CD / Rollouts**
- **Velero**
- **Квоты и метеринг**

Эти сервисы уже есть в Штурвале. Для ML их не ставят отдельно.

19 ML-компонентов

0 ручных установок

1 кнопка обновления

штурвал

ML-стек обновляется вместе с кластером

Совместимость драйверов NVIDIA с ядром, containerd, Kubernetes и Kubeflow проверяет команда Штурвала

Драйверы, плагины, Kubeflow и MLflow работают как сервисы кластера. Внутренний проект «починить GPU после апдейта» больше не нужен.

По кнопке или по расписанию

Обновление кластера включает GPU- и ML-стек

Изолированно по кластерам

Сначала тестовый кластер, потом прод. Один кластер не тянет за собой остальные

В закрытом контуре

Обновление идёт из вашего зеркала, без выхода в интернет

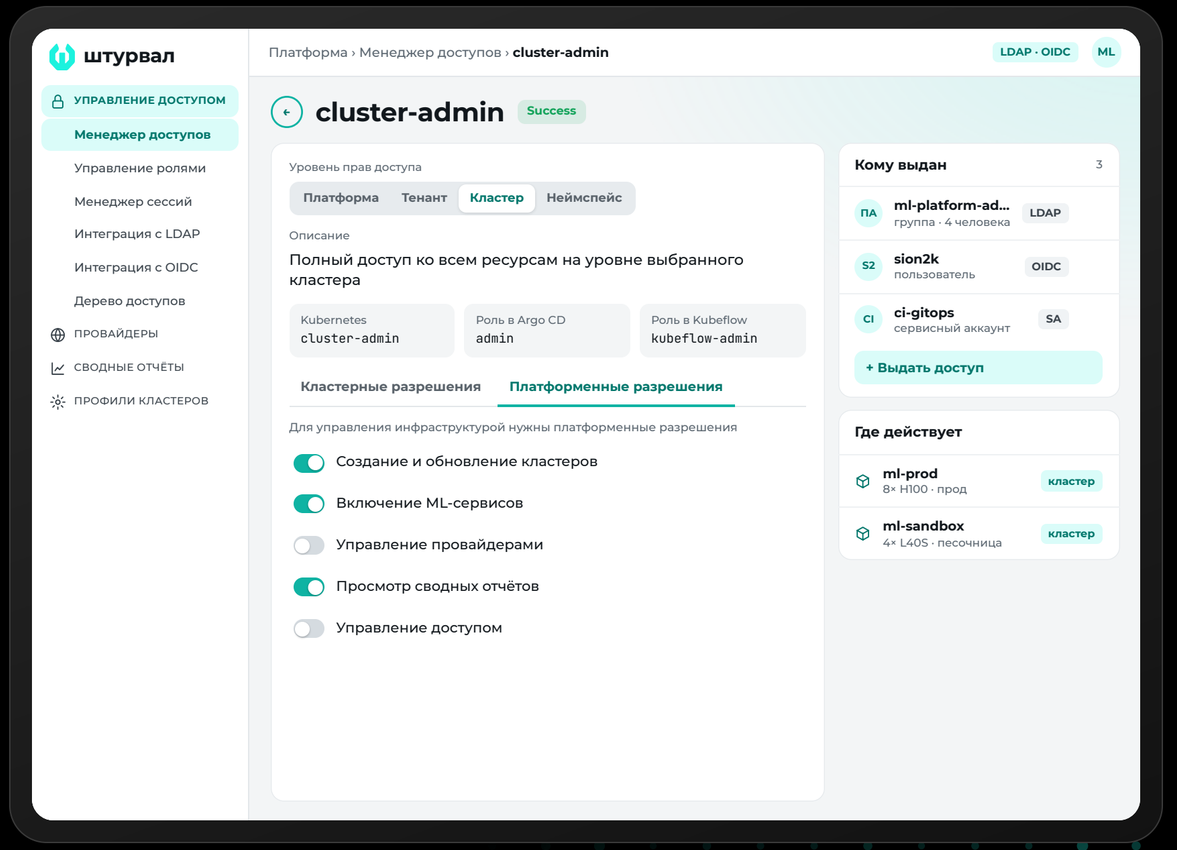
Отдельные кластеры для экспериментов и прода

Второй кластер создаётся из того же Штурвала и обслуживается из одной точки

штурвал

ML-кластер живёт по правилам всего Штурвала

- **Центральный кластер управления**
  ML-кластеры, песочницы и прод создаются, обновляются и мониторятся из одной точки
- **Единая ролевая модель**
  RBAC на уровнях платформы, тенанта, кластера и неймспейса. Вход через LDAP или OIDC, права на Kubeflow вместе с доступом к кластеру
- **Информационная безопасность**
  Trivy, в том числе по БДУ ФСТЭК, политики Kyverno, аудит в SIEM, закрытый контур
- **Автоматизации**
  Группы узлов, автомасштабирование, самовосстановление узлов, обновления по расписанию
- **Наблюдаемость, GitOps, бэкап**
  Метрики и дашборды Grafana с SSO, логи и алерты, Argo CD, Velero



штурвал

02

ЭКОНОМИЯ

Меньше простоя, меньше лишних серверов

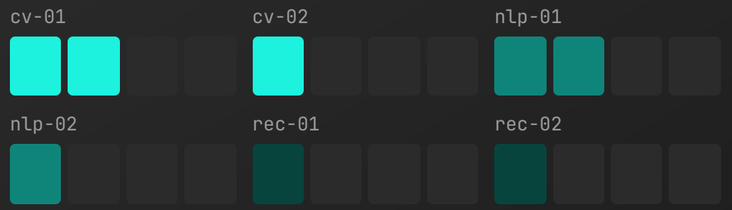
Нагрузка та же, но карты делят несколько команд по квотам. Свободная мощность не стоит в резерве у одной команды.

до 80% **экономии**
на GPU и эксплуатации

6→2 **сервера**
для тех же 9 задач в примере

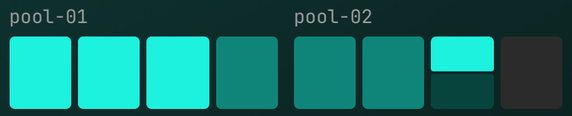
MIG **и Time-slice**
несколько задач на одной карте

Сейчас: сервер закреплён за командой



6 серверов, 24 карты: заняты 9, остальные простаивают у владельцев

Со Штурвалом: общий пул



2 сервера, 7 карт: те же 9 задач, две лёгкие делят карту через MIG

- Квоты, MIG и Time-slice вместо отдельного сервера на команду
- Автомасштабирование: резервный сервер не держат включённым
- Обучение и инференс на разных группах узлов

Экономия идёт от загрузки карт и меньшей ручной работы, а не от ускорения обучения.

штурвал

Гибко управляйте своими картами

Целая карта



Обучение на A100 из GPU-группы узлов

```yaml
# Обучение на A100 из GPU-группы
spec:
  nodeSelector:
    nvidia.com/gpu.product: NVIDIA-A100-SXM4-80GB
  tolerations:
    - key: nvidia.com/gpu
      effect: NoSchedule
  containers:
    - name: train
      resources:
        limits:
          nvidia.com/gpu: 1
```

Несколько карт



Дообучение LLM на четырёх H100 одного узла

```yaml
# Дообучение LLM на четырёх H100 одного узла
spec:
  nodeSelector:
    nvidia.com/gpu.product: NVIDIA-H100-80GB-HBM3
  containers:
    - name: train
      resources:
        limits:
          nvidia.com/gpu: 4
# Для обучения на нескольких узлах:
# PyTorchJob в Training Operator
```

MIG



Ноутбук на седьмой части карты

```yaml
# Ноутбук на седьмой части карты
spec:
  containers:
    - name: notebook
      resources:
        limits:
          nvidia.com/mig-1g.10gb: 1
# Остальные слайсы этой GPU
# доступны другим задачам
```

Time-slice

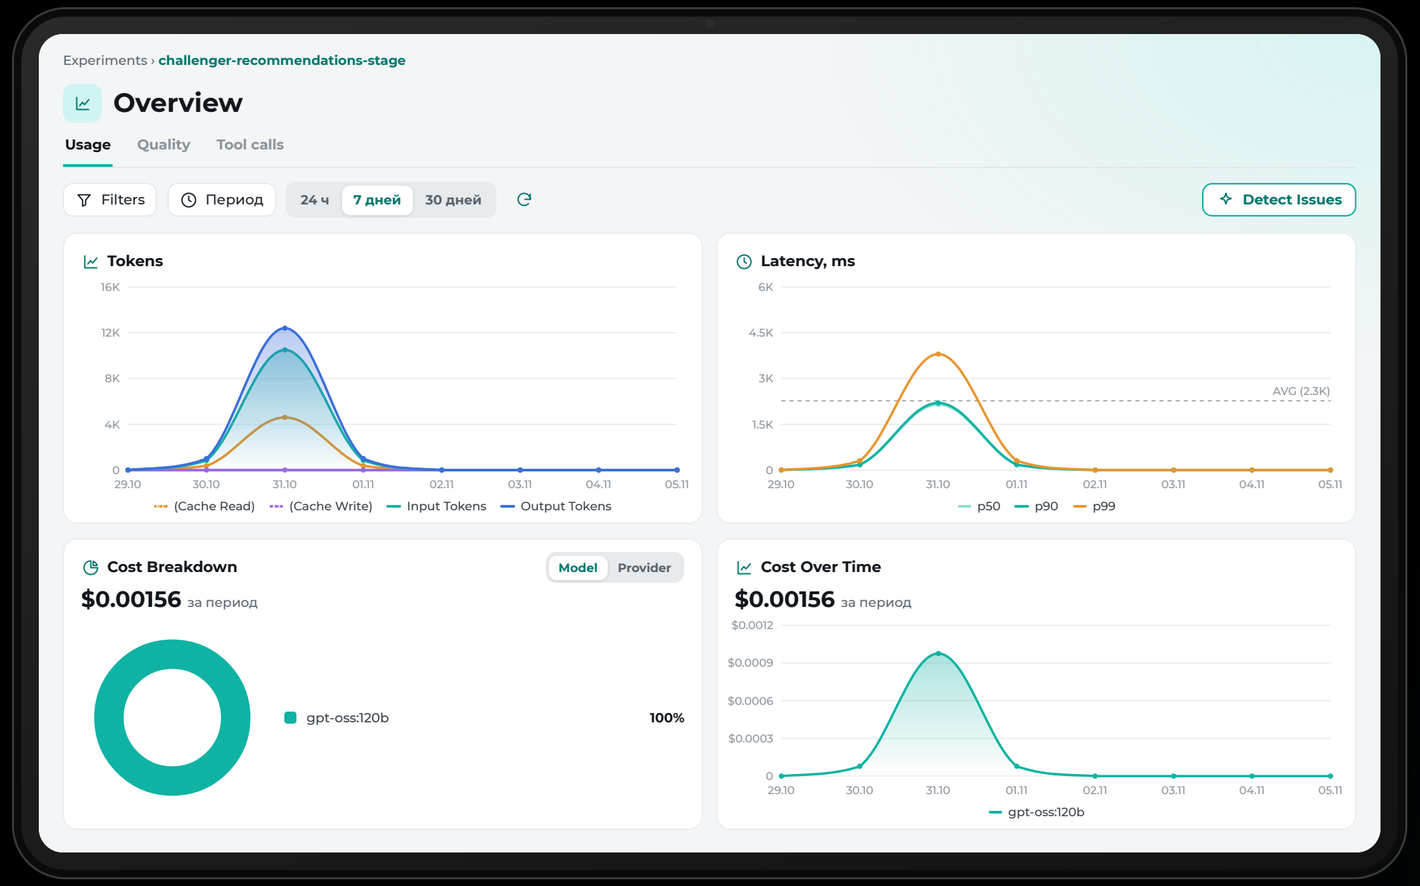


Ноутбук на карте, которую делят по времени

```yaml
# Ноутбук на карте, которую делят по времени
spec:
  nodeSelector:
    nvidia.com/gpu.sharing-strategy: time-slicing
  containers:
    - name: notebook
      resources:
        limits:
          nvidia.com/gpu: 1
# Одна физическая карта обслуживает
# несколько подов по очереди
```

штурвал

Потребление видно, расходы объяснимы



Запрос `limits: nvidia.com/gpu`

Задача команды запрашивает карту или её долю: MIG / Time-slice

Квота `Profile · quota`

Планировщик выдаёт ресурс в пределах лимита профиля

Метрики `DCGM · Prometheus`

Загрузка, память и простой по каждой карте и неймспейсу

Учёт `метеринг`

По данным о потреблении ведут внутренний учёт и планируют закупки

штурвал

Собрать ML-платформу можно. Дорого её поддерживать

	Своя сборка	Штурвал ML/AI
Собрать	ваша команда	ваша доля
Обновлять	ваша команда, каждый релиз	ваша доля
Закрывать уязвимости	ваша команда ИБ	ваша доля

Работу делает команда Штурвала, её стоимость разделена между всеми заказчиками

Если вы обновляете стек и закрываете уязвимости, Штурвал дешевле своей сборки

Схематично, без масштаба

штурвал

Лицензию Enterprise ML собирают из трёх параметров

Объект лицензирования

vCPU

Worker-нода

Физический сервер

Безлимит

Тип лицензии

Срочная
на срок по договорённости

Бессрочная
без ограничения срока

Уровень поддержки

Базовая
8×5

Продуктив
24×7

Штурвал уже используют

СОВКОМБАНК

ПОЧТА БАНК

НОВИКОМБАНК

БАНК ЦЕНТР-ИНВЕСТ

ЧЕЛЯБИНВЕСТБАНК

НБД Банк

БУДУЩЕЕ
ПЕНСИОННЫЙ ФОНД

CG CAPITAL GROUP

ГОЗНАК

ШЕРЕМЕТЬЕВО
МЕЖДУНАРОДНЫЙ АЭРОПОРТ

ҚАЗАҚТЕЛЕКОМ

media

МОСГОРГЕОТРЕСТ

и другие

ПОКАЖЕМ НА ВАШИХ GPU

Демо

Включение ML в кластере, общий пул GPU, квоты команд и обновление стека.

Пилот

На ваших GPU: каталог пользователей и одна-две команды.

Внедрение

Перенос ML-нагрузок, квоты, мониторинг и процессы обновления.

Попробовать самим

Community Edition Штурвала бесплатна, до 10 worker-узлов.

shturval@chislitellab.ru **docs.shturval.tech** **chislitellab.ru/shturval**